

## سوال ①:

الف) برای کاهش bias راهکارهای زیر را می توان استفاده کرد

1: انتخاب کردن Feature های بیشتر

2: با افزایش تعداد داده ها در training dataset

3: افزایش پیچیدگی مدل

ب) اگر ویژگی های یک مدل Correlated باشد، به این معناست

که این مدل در واقع overfit است که bias زیاد است و داده های

و همچنین واریانس نیز بالا است. به ضعف ویژگی های همبسته می گوییم

باعث می شود که bias کمتر شود، که این اتفاق حملن است Variance به

قدر ناچیزی افزایش پیدا کند که در کل مدل را بهتری کند

پ)

- دقت، با ثابت در نظر گرفتن پیچیدگی مدل و با افزایش داده ها

نویز را کمتر می کنیم و مدل بهتری شود.

- دقت، اگر مدل underfit باشد، اگر مدل overfit باشد، افزایش

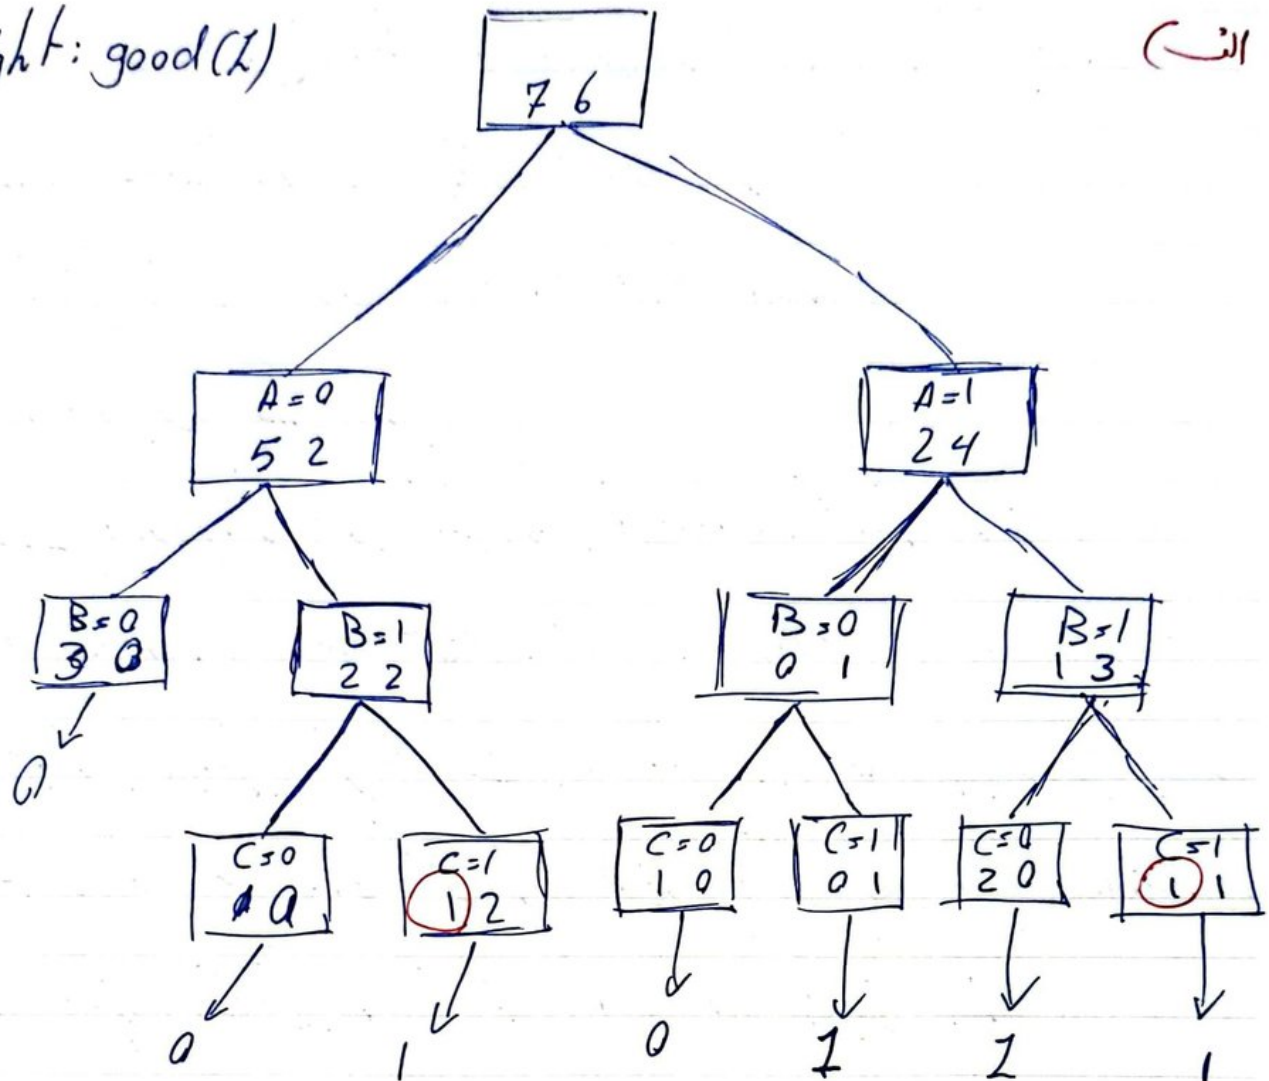
پیچیدگی، مدل را بهتری نمی کند.

left: bad (0)

سوال (2):

الف)

right: good (1)



$$\text{error} = \frac{2}{13} = 15.38\%$$

ب) حد اکثر خطا زمانی اتفاق می افتد که بین کلاس ها داریم،  
توانیم بعضی اتاقل سریم و برای همه یک حدس واحد بزنیم

در نتیجه

$$\text{error} = \frac{k-1}{k} = 1 - \frac{1}{k}$$



سوال (3):

الف) Multi-Class regression در واقع از softmax function استفاده می‌کنیم به صورتی که

$$P(y = y_i | x; w) = \frac{e^{w_i^T x}}{\sum_{i=1}^K e^{w_i^T x}} \rightarrow \text{که در آن } w \text{ یک ماتریس است.}$$

ب) در روش logistic regression در واقع هدف به دست آوردن  $w$  است (یعنی  $w_i$  ها)

$$L(w_1, \dots, w_{K-1}) = \sum_{i=1}^n \ln \{P(y = y_i | X = x_i)\} \quad \text{و} \quad \text{---}$$

$$= \sum_{i=1}^n \left\{ \ln \left\{ \frac{e^{w_{y_i}^T x_i}}{1 + \sum_{j=1}^{K-1} e^{w_j^T x_i}} \right\} \right\} = \sum_{i=1}^n \left\{ w_{y_i}^T x_i - \ln \left\{ 1 + \sum_{j=1}^{K-1} e^{w_j^T x_i} \right\} \right\}$$

$$= \sum_{i=1}^n w_{y_i}^T x_i - \sum_{i=1}^n \ln \left\{ 1 + \sum_{j=1}^{K-1} e^{w_j^T x_i} \right\}$$

ج) حال برای ماکسیمی کردن این بخش

عبارت  $\frac{\partial L}{\partial w_k}$  را تعریف می‌کنیم که تنها زمانی 1 است که  $y_i = k$

باشد و در غیر این صورت برابر با 0 است در نتیجه log-likelihood به شکل زیر می‌شود.

~~$$L = \sum_{k=1}^K \sum_{i=1}^n t_{i,k} w_k^T x_i - \sum_{i=1}^n \sum_{k=1}^K t_{i,k} \ln \left\{ 1 + \sum_{j=1}^{K-1} e^{w_j^T x_i} \right\}$$~~

$$L = \sum_{k=1}^K \sum_{i=1}^n t_{i,k} w_k^T x_i - \sum_{i=1}^n \sum_{k=1}^K t_{i,k} \ln \left\{ 1 + \sum_{j=1}^{K-1} e^{w_j^T x_i} \right\} \Rightarrow$$

$$\Rightarrow \nabla_{w_j} L = \sum_{i=1}^n t_{i,j} x_i - \sum_{i=1}^n \sum_{k=1}^K t_{i,k} x_i \frac{e^{w_j^T x_i}}{1 + \sum_{l=1}^{K-1} e^{w_l^T x_i}} \Rightarrow$$

$$\Rightarrow \nabla_{w_j} L = \sum_{i=1}^n \left\{ t_{i,j} - \frac{e^{w_j^T x_i}}{1 + \sum_{l=1}^{K-1} e^{w_l^T x_i}} \right\} x_i$$

$$h(w_1, \dots, w_{K-1}) = L(w_1, \dots, w_{K-1}) - \frac{\lambda}{2} \sum_{l=1}^{K-1} w_l^T w_l \quad (\rightarrow 0)$$

$$\nabla_{w_K} h = \nabla_{w_K} L - \frac{\lambda}{2} \sum_{l=1}^{K-1} \nabla_{w_K} (w_l^T w_l) = \nabla_{w_K} L - \lambda w_K \Rightarrow$$

$$\Rightarrow \nabla_{w_K} L = \sum_{i=1}^n \left\{ t_{i,j} - \frac{e^{w_j^T x_i}}{1 + \sum_{l=1}^{K-1} e^{w_l^T x_i}} \right\} x_i - \lambda w_K$$



سوال 4

الف) در واقع هدف ما اینست که  $\text{loss}$  کم کنیم. هدف ما اینست که  $\text{loss}$  کم کنیم.

تعریف می شود.  
Loss function:  $\frac{1}{2} \|y - Xw\|_2^2$

Loss function:  $\frac{1}{2} (y - Xw)^T (y - Xw) = \text{loss}$

$\nabla_w(\text{loss}) = \nabla_w \left\{ \frac{1}{2} (y - Xw)^T (y - Xw) \right\} = \nabla_w \left\{ \frac{1}{2} (y^T - w^T X^T) (y - Xw) \right\}$

$= \nabla_w \left\{ y^T y - y^T Xw - w^T X^T y + w^T X^T Xw \right\} \times \frac{1}{2} =$

$= -X^T y + X^T Xw$

$\nabla_w(\text{loss}) = 0 \Rightarrow \hat{w} = (X^T X)^{-1} X^T y$

حال اگر تنها به یک ویژگی بخواهیم این مدل را آموزش دهیم،

آنجا که  $x_i$  ها بجز  $x_0$  هم هستند در نتیجه

$$w_j = \frac{x_j^T y}{x_j^T x_j}$$

ب) اگر ستون ها ماتریس  $X$  متعامد باشند به این معنیست که

اگر  $x_i \neq 0 \rightarrow x_i^T x_j = 0$

پس در واقع ماتریس  $X^T X$  یک ماتریس قطری می شود که

$$(X^T X)_{ii} = x_i^T x_i$$

و جیقا چون که ماتریس  $X^T X$  یک ماتریس قطری است  
 $(X^T X)^{-1}$  نیز قطری است و روی قطر آن  $(X^T X)$

مقادیر به صورت زیر هستند:

$$(X^T X)^{-1}_{ii} = \frac{1}{x_i^T x_i}$$

و در نتیجه طبق قسمت قبل:  $\hat{w} = (X^T X)^{-1} X^T y$   
 و داریم که  $w_i = \frac{x_i^T y}{x_i^T x_i}$  که همان نتیجه گیری قسمت الف است.

~~$X = \begin{pmatrix} x_1 & x_2 & \dots & x_n \end{pmatrix}$~~   $X = (1 \ x)$  (—)